



基于深度学习的光伏发电量预测方法的实现与分析

汇报人：高海涛
指导老师：刘春山

杭州电子科技大学

2023 年 6 月 3 日



目录

- 1 Motivation
 - Why We Need PV
 - Why We Need AI to Predict PV
- 2 My Experiment
 - Project Statement
 - Dataset Introduction
 - My Model
 - Short Forecasting
 - Long Forecasting
- 3 Conclusion




- 1 Motivation
 - Why We Need PV
 - Why We Need AI to Predict PV
- 2 My Experiment
 - Project Statement
 - Dataset Introduction
 - My Model
 - Short Forecasting
 - Long Forecasting
- 3 Conclusion





Why We Need PV

光伏新能源



- 清洁
- 可再生
- 无限





Why We Need AI to Predict PV

未来



- 建模**复杂**的环境
- 利用**多模态**的**海量**数据

1 Motivation

- Why We Need PV
- Why We Need AI to Predict PV

2 My Experiment

- Project Statement
- Dataset Introduction
- My Model
- Short Forecasting
- Long Forecasting

3 Conclusion



Project Goals & Problem Problems

Problems

- 传感器还有大量无用特征
- 基站缺乏昂贵的数据采集器
- 数据不平稳，波动较大




Fig 1: 有功功率的变化图




Fig 2: 特征图



Project Goals & Problem

Goals

本次毕业设计的目标

开发基于**深度学习**算法的尽可能使用**少量**特征，在**短期**和**长期**预测预测中均达到较高精度的光伏发电量预测系统



Dataset

浙江台州光伏传感器

如表1所示

Table: Dataset

时间戳	发电量	直流电流	逆变器温度	...	天气
2021-4-1 00:00:00	0	0	18	...	晴
2021-4-1 01:00:00	99	100	50	...	晴
2021-4-1 02:00:00	128	100	50	...	晴
...
2022-12-30 23:00:00	0	0	20	...	小雨

15000 rows-29 cols



My Model

Patch-LSTM




Fig 3: Patch-LSTM

Patch

LSTM



Why Patch & Why LSTM?

Why Patch?

- 论文 *A TIME SERIES IS WORTH 64 WORDS: LONG-TERM FORECASTING WITH TRANSFORMERS* 指出, Patch 可以提高 Attention 机制对于时间序列的特征的捕捉能力.

Why LSTM?

- 论文 *Are Transformers Effective for Time Series Forecasting?* 实验表明, Transformer 类模型相较于 MLP 对于时间序列信息的学习并没有明显优势,甚至不如 MLP 的预测结果. 如果比较 MLP 与 LSTM 大量研究表明, LSTM 更适合时间序列

[1]Nie Y, Nguyen N H, Sinthong P, 等. *A Time Series is Worth 64 Words: Long-term Forecasting with Transformers*[J]. *arXiv*, 2022.

[2]Zeng A, Chen M, Zhang L, 等. *Are Transformers Effective for Time Series Forecasting?*[J]. *arXiv*, 2022



Short Forecasting

ARIMA VS Patch-LSTM




Fig 4: ARIMA Data Split



ARIMA

定阶

Algorithm 1: Grid Search

输入: $p, d = 0, q$

输出: AIC

```

1  初始化变量;
2  for  $p = 1$  to 5 do
3      for  $q = 1$  to 5 do
4          if  $AIC$  是最小值 then
5              保留  $AIC$  和
                (p,d,q);
6          end
7      else
8          continue;
9  end
  
```

如表2所示

Table: Arguments

参数	值
p	2
d	0
q	2
AIC	-1723.75



ARIMA 预测




Fig 5: ARIMA 预测图




Fig 6: ARIMA 预测局部放大图

Table: Evaluation Metrics

Metric	Value
MSE	0.0013888212092888917
RMSE	0.03726689159681676
MAE	0.02743285985117187



Patch-LSTM Short Forecasting

特征: 历史数据 & 天气信息




Fig 6: Patch-LSTM 短期预测图

Table: Evaluation Metrics

Metric	Value
MSE	0.00028879829915240407
RMSE	0.016994066586676775
MAE	0.00970529392361641



Analysis Graphs




Fig 7: Patch-LSTM 预测图




Fig 8: ARIMA 预测局部放大图




Fig 9: Metrics 对比图



Conclusion1

- ARIMA 在短期预测中已经足够优秀
- 基于深度学习的模型在短期预测中精度比 ARIMA 略高
- 基于深度学习的模型的另一个优势是如果有可用的其他外部信息，仍可以输入模型，而 ARIMA 属于单变量模型



Model Introduction

MLP & DLinear

MLP

- 全连接
- 非线性激活函数
- 适应性强




Fig 10: MLP 模型架构

DLinear

- 分解
- 一步预测




Fig 11: DLinear 模型架构

[1]Peng Z. *Multilayer Perceptron Algebra*[J]. *arXiv*, 2017.

[2]Zeng A, Chen M, Zhang L, 等. *Are Transformers Effective for Time Series Forecasting?*[J]. *arXiv*, 2022



Data Split

train,valid,test




Fig 12: Train Valid Test Split



MLP Long Forecasting

特征：历史数据




Fig 13: MLP 预测图




Fig 14: MLP 预测局部放大图

Table: Evaluation Metrics

Metric	Value
MSE	0.005282088648527861
RMSE	0.07267797911697779
MAE	0.03936387971043587
MAPE	1.4119446



DLinear Long Forecasting

特征：历史数据




Fig 15: DLinear 预测图




Fig 16: DLinear 预测局部放大图

Table: Evaluation Metrics

Metric	Value
MSE	0.005549801047891378
RMSE	0.07449698683766598
MAE	0.0542387031018734
MAPE	1.5561291



Patch-LSTM Long Forecasting

特征：历史数据




Fig 17: Patch-LSTM 预测图




Fig 18: Patch-LSTM 预测局部放大图

Table: Evaluation Metrics

Metric	Value
MSE	0.003447531256824732
RMSE	0.05871568152397392
MAE	0.0294288732111454
MAPE	0.8023116



Analysis Graphs




Fig 19: Metrics 对比图




Fig 20: MSE 放大图





Conclusion2

- MSE (均方误差): Patch LSTM 模型表现最好, 为 0.0034, 其次是 MLP 和 DLinear 模型, 分别为 0.0053 和 0.0055。说明 Patch LSTM 在预测值与实际值之间的误差方差最小。
- RMSE (均方根误差): Patch LSTM 模型表现最好, 为 0.0587, 其次是 MLP 和 DLinear 模型, 分别为 0.0727 和 0.0745。说明 Patch LSTM 在预测值与实际值之间的误差方差开根号后最小。
- MAE (平均绝对误差): Patch LSTM 模型表现最好, 为 0.0294, 其次是 DLinear 模型和 MLP, 分别为 0.0542 和 0.0394。说明 Patch LSTM 在预测值与实际值之间的误差绝对值的平均值最小。
- MAPE (平均绝对误差百分比): Patch LSTM 模型表现最好, 为 0.8023, 其次是 MLP 和 DLinear 模型, 分别为 1.4119 和 1.5561。说明 Patch LSTM 在预测值与实际值之间的误差绝对值的平均百分比最小。





1 Motivation

- Why We Need PV
- Why We Need AI to Predict PV

2 My Experiment

- Project Statement
- Dataset Introduction
- My Model
- Short Forecasting
- Long Forecasting

3 Conclusion





Summary

模型

- 短期预测中，Patch-LSTM 的性能略好于 ARIMA，尤其在 0 值附近，但是在峰值附近有一定偏移
- 在长期预测中，Patch-LSTM 性能显著优于经典深度学习模型 MLP，和最新提出的 DLinear
- 在长期和短期预测中均取得优势，且在深度学习训练过程中，只采用了少量特征-天气，或者只使用待预测特征本身历史数据

汇报完毕 恳请指正

Presented by
高海涛

